

### Задание 1.

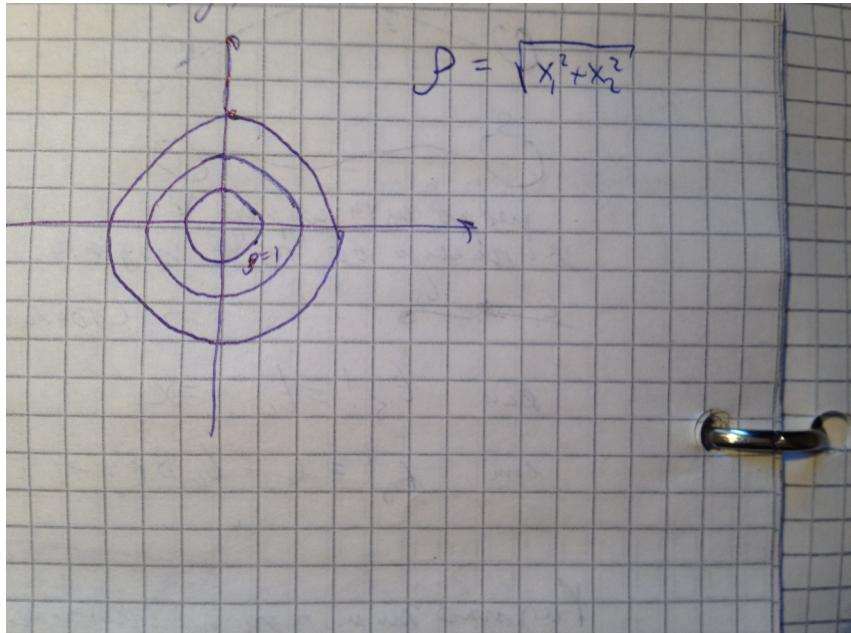
1) т.к. выборка имеет малый размер, то имеет смысл использовать leave-one-out. Т.к. если использовать k-fold, то модель будет каждый раз недообучаться, т.к. данных и так мало. Так же это не займет много времени из-за размера выборки.

2) т.к. выборка большая, то leave-one-out будет очень долго считаться, поэтому надо использовать k-fold, и т.к. данных много, то потеря sample.size()/k данных должно не сильно повлиять на обобщающую способность модели и будет противостоять переобучению.

### Задание 2.

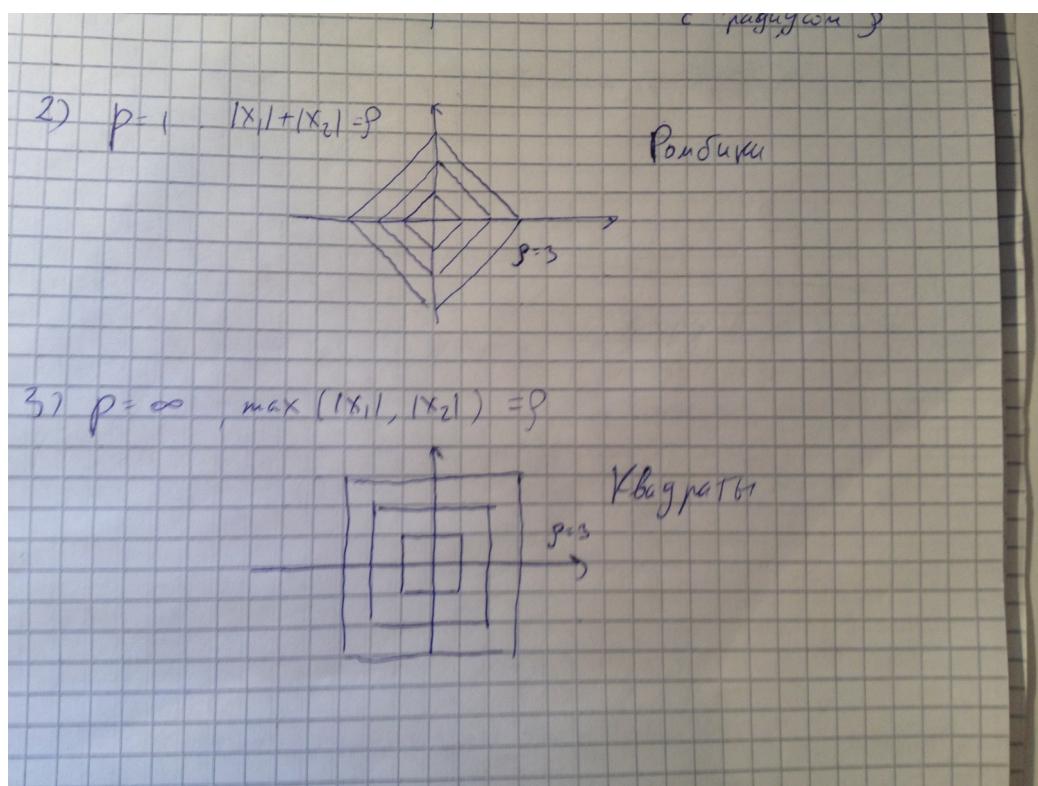
1)  $p = 2$

окружности с центром в начале координат



2) ромбики

3) квадраты



Задание 3.

$$P(\min_{i=1 \dots l} g(0, x_i) \leq p) = 1 - P(g(0, x_1) > p, \dots, g(0, x_l) > p) =$$
$$= 1 - P(g(0, x_1) > p) \cdot \dots \cdot P(g(0, x_l) > p) =$$

независима

$$= 1 - (1 - p^n)^l$$

равномерно

$$1 - (1 - p^{\frac{n}{2}})^l = \frac{1}{2}$$

$$(1 - p^{\frac{n}{2}}) = \sqrt[l]{\frac{1}{2}}$$

$$p^{\frac{n}{2}} = \left(1 - \sqrt[l]{\frac{1}{2}}\right)^{\frac{1}{l}}$$

$$\text{при } n \rightarrow \infty \quad p^{\frac{n}{2}} \rightarrow 1$$

$$1) n=10 \quad l=500 \Rightarrow p^{\frac{1}{2}} = 0.51$$

$$2) n=100 \quad l=500 \Rightarrow p^{\frac{1}{2}} = 0.936$$

$$3) n=1000 \quad l=500 \Rightarrow p^{\frac{1}{2}} = 0.9934$$

Задание 4.

$$1) p = \begin{cases} 1 & (0, 1, x_1) \\ 0.5 & (0.5, x_2) \end{cases}$$

$$\begin{aligned} P(|x_2| + |0.5| < |x_1| + |0.1|) &= P(x_2 + 0.4 < x_1) - \\ &= P(x_2 < x_1 - 0.4) = \frac{1}{2} \cdot 0.6 \cdot 0.6 = \frac{1}{2} \cdot 0.6 \cdot 0.6 = \\ &= 0.18 \end{aligned}$$

$$2) P\left(\left(x_2^q + 0.5^q\right)^{\frac{1}{q}} < \left(x_1^q + 0.1^q\right)^{\frac{1}{q}}\right) =$$

$$= \int_a^b \int_0^{(x_1^q + 0.1^q - 0.5^q)^{\frac{1}{q}}} dx_2 dx_1$$

$$\underline{I} q=2 \Rightarrow \int_{\sqrt{0.24}}^1 \int_0^{\sqrt{x_1^2 - 0.24}} dx_2 dx_1 = \int_{\sqrt{0.24}}^1 \sqrt{x_1^2 - 0.24} dx_1 =$$

$$= \frac{1}{10} x_1 \sqrt{25x_1^2 - 6} - \frac{3}{25} \log(\sqrt{25x_1^2 - 6} + 5x_1) \Big|_{\sqrt{0.24}}^1$$

$$3) P(\max(|x_1|, |0.1|) > \max(|x_2|, |0.5|)) =$$

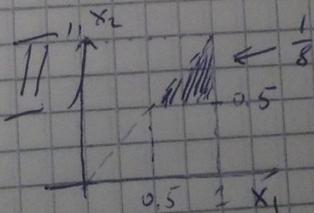
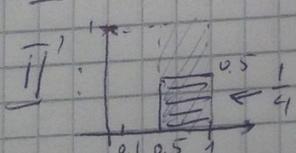
$$= \frac{1}{4} + \frac{1}{8} = \frac{3}{8}$$

$$\underline{I} x_1 \leq 0.1 \Rightarrow P(0.1 > \max(x_2, 0.5)) = 0$$

$$\underline{II} x_1 > 0.1 \Rightarrow P(x_1 > \max(x_2, 0.5)) \quad \text{разобьем на случаи}$$

$$\underline{II}' P(x_1 > 0.1, x_2 \leq 0.5, x_1 > 0.5) = \frac{1}{4}$$

$$\underline{II}'' P(x_1 > 0.1, x_2 > 0.5, x_1 > x_2) = \frac{1}{8}$$



### Задание 5.

“Чем больше метод машинного обучения склонен к переобучению, тем больше настраиваемых параметров у него должно быть.” Алгоритм склонен к переобучение, если он начинает подстраиваться под каждого представителя выборки и плохо перестает экстраполировать и представлять всю генеральную совокупность целиком. Это заложено в методе построение алгоритма(допускает ли он подогнанность с числом операций под конкретную выборку), а многие настраиваемые параметры могут наоборот способствовать предотвращению оверфита. Например в xgboost есть параметры регуляризации, максимальная глубина, минимальное число элементов в листе, минимальное улучшение на каждом шаге и другие.

В данном примере линейная модель строит одну кривую по всем точкам для всей выборки. А k-NN для каждого отдельного элемента выборки определяет его класс, тем самым он более гибко описывает множество объектов.

### Задание 6.

Рассмотрим алгоритм построение дерева:

1) в каждой вершине дерева мы бежим циклом длины n, т.е. количеству фичей.(ищим на

какой фиче наилучшее разбиение);

2) внутри этого цикла (т.е. для каждой фичи), мы сначала сортируем значения фичи за  $O(l \log(l))$ (где l размер выборки)

затем мы один раз за  $O(l)$ , подсчитываем функционал качества(ошибку), отдельно храним ошибку справа от разделителя и слева.

Теперь мы должны пройтись циклом по всем уникальным отсортированным значениям фичи (не длиннее l), но нам не надо еще каждый раз считать за l операций ошибку, за счет особого хранения можно не всю ее заного пересчитывать, а вычесть из правой части ошибку по длине сдвига и прибавлять к левой.

Затем выбирается точка, на которой был достигнут минимум  $O(l)$  и смотрят на другую фичу.

3) всего вершин в дереве некоторая константа, которую мы контролируем (`max_depth`) она не влияет на асимптотику

Итого получили:  $O(n(l \log(l) + l + l + l)) = O(n l \log(l))$

Задание 7.

$$1) \mathbb{E} |R_m| = n = n_1 + \dots + n_K$$

$$\frac{1}{n} \mathbb{E} \sum_{i=1}^n \mathbb{I}(y_i \neq K_i) = \mathbb{E} \sum_{i=1}^K \sum_{j=1}^{n_i} \mathbb{I}(x_{ji} \neq i) =$$

$$= \sum_{i=1}^K p_{mik} \mathbb{E}(\mathbb{I}(x_{ji} \neq i)) = \sum_{i=1}^K p_{mik} (1 - p_{mik})$$

$$\begin{aligned} \mathbb{E} |R_m| &= \sum_{i=1}^K \sum_{j=1}^{n_i} \\ &= \sum_{k=1}^K \sum_{i=1}^{n_k} \end{aligned}$$

$$2) \sum_{K=1}^K p_{mik} (1 - p_{mik}) = \sum_{\substack{K \neq \max p_{mik} \\ K}} p_{mik} (1 - p_{mik}) + p_{\max} (1 - p_{\max}) \Rightarrow$$

$\Rightarrow$  рассмотрим разницу

$$\sum_{\substack{K \neq \max p_{mik} \\ K}} p_{mik} (1 - p_{mik}) + p_{\max} (1 - p_{\max}) - (1 - p_{\max}) =$$

$$\begin{aligned} &= \sum_{K \neq \max p_{mik}} p_{mik} (1 - p_{mik}) - (1 - p_{\max})^2 \geq \sum_{K \neq \max p_{mik}} p_{mik} (1 - p_{\max}) - (1 - p_{\max})^2 \\ &\geq (1 - p_{\max}) \left( \sum_{K \neq \max p_{mik}} p_{mik} - 1 \right) = (1 - p_{\max}) \left( \sum_{K=1}^K p_{mik} - 1 \right) = 0 \end{aligned}$$

$\Rightarrow$  преобразующий класс не является  $a(x)$

$$3) \frac{1}{n} \sum_{i=1}^n \mathbb{I}(y(x_i) = K) - \bar{y} \stackrel{?}{=} \bar{y} = \frac{\sum_{i=1}^n \mathbb{I}(y(x_i) = K)}{n} = p_{mik}$$

$$\bar{y}_{ik} = \mathbb{I}(y(x_i) = k)$$

$$\Leftrightarrow \frac{1}{n} \sum_{K=1}^K \left( p_{mik} \cdot n - p_{mik} \cdot (p_{mik} \cdot n) + n p_{mik}^2 \right) =$$

$$\Leftrightarrow \sum_{K=1}^K (p_{mik} - p_{mik}^2) = \sum_{K=1}^K p_{mik} (1 - p_{mik})$$